

# Trabalho Computacional: Modelos de Regressão e Classificação

Karlos Eduardo Sousa Pinto  
Engenharia da Computação  
Universidade de Fortaleza (UNIFOR)  
Fortaleza, Brasil  
karlos2320262@edu.unifor.br

Kayo Nicholas Gomes Alcantara  
Engenharia da Computação  
Universidade de Fortaleza (UNIFOR)  
Fortaleza, Brasil  
kayo.nicholas@edu.unifor.br

**Abstract**—Este trabalho apresenta o desenvolvimento e avaliação de modelos preditivos supervisionados aplicados a duas tarefas. Na regressão, dados de velocidade do vento de um aerogerador foram utilizados para prever potência gerada, comparando Mínimos Quadrados Ordinários (MQO), MQO regularizado por Tikhonov e modelo de média, validados por Random Subsampling com  $R = 500$  rodadas e particionamento 80/20, usando MSE e  $R^2$  como métricas. Na classificação, sinais de eletromiografia facial foram utilizados para reconhecer cinco expressões, implementando seis classificadores — MQO, Gaussiano Tradicional, Gaussiano com Covariâncias Iguais, Covariância Agregada, Naive Bayes e Gaussiano Regularizado de Friedman — validados por Monte Carlo com  $R = 500$  rodadas. O parâmetro ótimo do modelo de Friedman foi determinado por validação cruzada k-fold. Os resultados indicam que classificadores gaussianos com fronteiras quadráticas superaram modelos lineares, refletindo a não separabilidade linear dos dados no espaço bidimensional de características.

**Index Terms**—Regressão Linear; Classificação; Machine Learning; Aprendizado de Máquina Supervisionado.

## I. INTRODUÇÃO

Modelos preditivos são treinados a partir de pares entrada-saída conhecidos, com o objetivo de generalizar o conhecimento adquirido para novas observações. A escolha do modelo mais adequado para uma determinada tarefa, contudo, não é trivial e depende fortemente das características dos dados e da natureza do problema. Nesse contexto, o presente trabalho propõe a implementação e comparação sistemática de diferentes modelos preditivos supervisionados em duas tarefas distintas. Na primeira, aborda-se um problema de regressão, em que se busca estimar a potência gerada por um aerogerador a partir da velocidade do vento. Na segunda, trata-se de um problema de classificação, em que sinais de eletromiografia (EMG) captados em músculos faciais são utilizados para reconhecer cinco expressões faciais distintas. Para cada tarefa, múltiplos modelos são implementados, comparados e validados estatisticamente, permitindo uma análise criteriosa sobre o comportamento e o desempenho de cada abordagem. Todos os modelos foram desenvolvidos sem o uso de bibliotecas de aprendizado de máquina prontas, utilizando exclusivamente NumPy e Matplotlib.

## II. METODOLOGIA

Cada etapa foi conduzida em frentes independentes, cada uma com seu próprio conjunto de dados, modelos e protocolo de avaliação. A seguir, descrevem-se as decisões adotadas em cada etapa.

### A. Tarefa de Regressão

1) *Conjunto de Dados*: O conjunto de dados utilizado na tarefa de regressão é o arquivo aerogerador.dat. A variável independente corresponde à velocidade do vento, medida em m/s, e a variável dependente corresponde à potência elétrica gerada, medida em kW. Os dados foram organizados em uma matriz de regressores, com coluna de intercepto incluída, e um vetor de respostas.

2) *Modelos Implementados*: Três famílias de modelos foram implementadas e comparadas:

a) *1. Média da Variável Dependente*: Utilizado como baseline. Esse modelo prevê para todas as observações o valor médio de  $y$  calculado sobre o conjunto de treinamento, sem considerar qualquer relação com a variável independente.

b) *2. MQO Tradicional*: Estima o vetor de parâmetros  $\beta$  minimizando a soma dos erros quadráticos entre os valores preditos e os valores reais. A solução fechada é obtida pela equação normal:

$$\beta = (X^T X)^{-1} X^T y$$

c) *3. MQO Regularizado (Tikhonov)*: Uma extensão do MQO que adiciona um termo de penalização controlado pelo hiperparâmetro  $\lambda$ , com o objetivo de reduzir o sobreajuste. Foram testados os valores  $\lambda \in \{0; 0,25; 0,5; 0,75; 1,0\}$ , totalizando cinco variantes do modelo regularizado.

3) *Validação e Métricas*: A validação foi conduzida pelo método Random Subsampling, com  $R = 500$  rodadas. Em cada rodada, os dados foram particionados aleatoriamente em 80% para treinamento e 20% para teste. As métricas de desempenho adotadas foram o Erro Quadrático Médio (MSE) e o coeficiente de determinação  $R^2$ , calculados sobre o conjunto de teste em cada rodada. Ao final, foram computadas a média, o desvio-padrão, o valor máximo e o valor mínimo de cada métrica para cada modelo.

## B. Tarefa de Classificação

1) *Conjunto de Dados*: O conjunto de dados utilizado na tarefa de classificação provém do arquivo EMGDataset.csv, composto por 50.000 amostras de sinais de eletromiografia (EMG). Os sinais foram captados em dois músculos faciais: o Corrugador do Supercílio (Sensor 1) e o Zigomático Maior (Sensor 2), utilizando uma taxa de amostragem de 1 kHz e resolução de 12 bits. As amostras estão rotuladas em cinco classes: (1) Neutro, (2) Sorriso, (3) Sobrancelhas Levantadas, (4) Surpreso e (5) Rabugento. Os dados foram organizados na matriz de atributos  $\mathbf{X} \in \mathbb{R}^{N \times p}$  para o classificador MQO e transpostos para  $\mathbf{X} \in \mathbb{R}^{p \times N}$  no caso dos classificadores Gaussianos Bayesianos, onde  $N$  = número de amostras e  $p$  = número de sensores.

### 2) Modelos Implementados:

a) **1. MQO Tradicional**: Adaptado para classificação utiliza codificação nas classes e estima uma matriz de coeficientes  $\beta$  via pseudo-inversa. A classe predita é aquela correspondente à maior saída da função linear.

b) **2. Classificador Gaussiano Tradicional (QDA)**: Modela cada classe com sua própria distribuição gaussiana multivariada, estimando individualmente a média e a matriz de covariância de cada classe. As fronteiras de decisão resultantes são quadráticas.

c) **3. Classificador Gaussiano com Covariâncias Iguais (LDA)**: Assume que todas as classes compartilham uma única matriz de covariância, obtida pela média ponderada das covariâncias individuais. Isso impõe fronteiras de decisão lineares entre as classes.

d) **4. Classificador Gaussiano (Cov. Agregada)**: Utiliza como covariância comum a matriz de covariância calculada sobre todo o conjunto de treinamento, sem ponderação por classe.

e) **5. Classificador de Bayes Ingênuo (Naive Bayes)**: Assume a independência condicional entre os atributos dada a classe. Estruturalmente, isso equivale a utilizar apenas a diagonal da matriz de covariância de cada classe, assumindo que as covariâncias cruzadas são nulas.

f) **6. Classificador Gaussiano Regularizado (Friedman)**: Propõe uma abordagem de regularização que interpola continuamente entre o QDA e o LDA por meio do hiperparâmetro  $\lambda \in [0, 1]$ . Quando  $\lambda = 0$  o modelo recupera o comportamento do QDA, com fronteiras quadráticas; quando  $\lambda = 1$  equivale ao LDA, com fronteiras lineares, tornando o modelo mais flexível e menos suscetível a instabilidades numéricas decorrentes de matrizes de covariância mal condicionadas.

3) *Seleção do Hiperparâmetro  $\lambda$  (Friedman)*: O valor ótimo de  $\lambda$  para o classificador de Friedman foi determinado por validação cruzada k-fold com  $K = 5$  folds, avaliando a acurácia média para cada valor de  $\lambda \in \{0; 0,001; 0,01; 0,1; 0,2; 0,3; 0,4; 0,5; 0,6; 0,7; 0,8; 0,9; 1\}$ . O valor que maximizou a acurácia média de validação foi selecionado como  $\lambda$  ideal para uso na etapa de Monte Carlo.

4) *Validação e Métricas*: A validação dos classificadores foi realizada por simulação de Monte Carlo com  $R = 500$

rodadas. Em cada rodada, os dados foram particionados aleatoriamente em 80% para treinamento e 20% para teste. A métrica de desempenho adotada foi a acurácia (taxa de acerto). Ao final das 500 rodadas, foram calculadas a média, o desvio-padrão, o valor máximo e o valor mínimo da acurácia para cada modelo.

## III. RESULTADOS

### A. Tarefa de Regressão

1) *Análise dos Dados*: O gráfico (Figura 1) evidencia uma forte correlação positiva entre a velocidade do vento e a potência gerada. Observa-se que para velocidades inferiores a 6 m/s a potência permanece próxima de zero, refletindo a velocidade mínima do aerogerador. Entre 6 e 12 m/s, a relação torna-se aproximadamente linear. Acima de 12 m/s, a potência se estabiliza em torno de 500 kW. Este comportamento sugere que um modelo linear pode ajustar bem a faixa intermediária, mas apresentará limitações nas extremidades da curva.




Fig. 1. Análise de regressão entre velocidade do vento e potência.

2) *Ajuste dos Modelos*: A Figura 2 apresenta o ajuste visual dos seis modelos implementados sobre os dados do aerogerador. O modelo de média da variável dependente produz uma linha horizontal constante em aproximadamente 298,37 kW, representando um preditor constante que ignora completamente a relação entre a velocidade do vento e a potência gerada, sendo incapaz de acompanhar qualquer tendência dos dados.




Fig. 2. Ajuste dos modelos de regressão com os dados do aerogerador.

3) *Validação por Random Subsampling (R=500)*: As Tabelas I e II apresentam as estatísticas de desempenho ( $MSE$  e  $R^2$ ) calculadas ao longo das 500 rodadas de validação para cada modelo.

TABLE I  
RESULTADOS DE MSE — RANDOM SUBSAMPLING (R=500)

| MODELO                  | MÉDIA    | DESVIO-PADRÃO | MÁX.     | MÍN.   |
|-------------------------|----------|---------------|----------|--------|
| Média da var. dep.      | 11140,32 | 619,13        | 13237,72 | 9346,4 |
| MQO Tradicional         | 778,64   | 166,08        | 1298,09  | 459,11 |
| Tikhonov $\lambda=0$    | 778,64   | 166,08        | 1298,09  | 459,11 |
| Tikhonov $\lambda=0,25$ | 778,64   | 166,05        | 1297,96  | 459,17 |
| Tikhonov $\lambda=0,5$  | 778,64   | 166,02        | 1297,83  | 459,24 |
| Tikhonov $\lambda=0,75$ | 778,64   | 165,98        | 1297,7   | 459,3  |
| Tikhonov $\lambda=1$    | 778,64   | 165,95        | 1297,57  | 459,37 |

TABLE II  
RESULTADOS DE  $R^2$  — RANDOM SUBSAMPLING (R=500)

| MODELO                  | MÉDIA   | DESVIO-PADRÃO | MÁX.   | MÍN.    |
|-------------------------|---------|---------------|--------|---------|
| Média da var. dep.      | -0,0026 | 0,0037        | 0      | -0,0363 |
| MQO Tradicional         | 0,9301  | 0,0136        | 0,9566 | 0,8866  |
| Tikhonov $\lambda=0$    | 0,9301  | 0,0136        | 0,9566 | 0,8866  |
| Tikhonov $\lambda=0,25$ | 0,9301  | 0,0136        | 0,9566 | 0,8866  |
| Tikhonov $\lambda=0,5$  | 0,9301  | 0,0136        | 0,9565 | 0,8866  |
| Tikhonov $\lambda=0,75$ | 0,9301  | 0,0136        | 0,9565 | 0,8866  |
| Tikhonov $\lambda=1$    | 0,9301  | 0,0136        | 0,9565 | 0,8866  |

O modelo de média da variável dependente apresentou desempenho muito inferior aos demais, com MSE médio de 11.140,32 e  $R^2$  médio de  $-0,0026$ , confirmando sua incapacidade de capturar qualquer padrão entre as variáveis. O  $R^2$  negativo indica que este modelo performa pior do que simplesmente prever a média dos dados de teste, o que é esperado para um preditor constante calculado no treino.

O MQO tradicional e todos os modelos de Tikhonov obtiveram desempenho idêntico na prática, com MSE médio de 778,64 e  $R^2$  médio de 0,9301, demonstrando que a regularização de Tikhonov não trouxe ganho relevante neste cenário de baixa dimensionalidade ( $p = 1$ ) e dados abundantes. O desvio-padrão do MSE ficou em torno de 166, refletindo a variabilidade natural dos particionamentos aleatórios.

### B. Tarefa de Classificação

1) *Análise dos Dados*: O gráfico de espalhamento (Figura 3) revela uma estrutura de classes com separabilidade parcial no espaço dos sensores. A classe Sorriso (amarelo) concentra-se na região de alto valor do Sensor 2 e baixo valor do Sensor 1, enquanto a classe Rabugento (vermelho) distribui-se predominantemente na faixa de valores médios-altos do Sensor 1. As classes Neutro e Sobrancelhas Levantadas aparecem próximas à origem com baixa amplitude em ambos os sensores. A classe Surpreso distribui-se de forma mais compacta na região inferior esquerda. Essa distribuição indica que o problema não é linearmente separável, favorecendo modelos com fronteiras de decisão quadráticas.




Fig. 3. Gráfico de espalhamento - Sinais EMG por expressão facial.

2) *Fronteiras de Decisão e Acurácia nos Dados Completos*: A Figura 4 exibe as fronteiras de decisão aprendidas por cada modelo sobre o conjunto completo de dados. O MQO, por impor fronteiras lineares no espaço de saída, obteve acurácia de apenas 72,41%, pois não consegue delinear as regiões não-lineares características deste problema. Os classificadores gaussianos com covariâncias individuais (QDA e Friedman) apresentaram fronteiras quadráticas bem adaptadas às distribuições das classes, com QDA atingindo 96,68% e Friedman ( $\lambda = 0,01$ ) 97,97%. O classificador LDA (Covariâncias Iguais) e o Naive Bayes também superaram 96%, evidenciando que mesmo hipóteses simplificadoras dos modelos gaussianos são suficientes para capturar a estrutura das classes.




Fig. 4. Fronteiras de decisão dos modelos de classificação no espaço EMG.

3) *Seleção do Hiperparâmetro  $\lambda$  (K-Fold,  $K = 5$ ):* A validação cruzada  $k$ -fold com  $K = 5$  foi aplicada para selecionar o  $\lambda$  ideal do classificador de Friedman. A Figura 5 apresenta a curva de acurácia média em função de  $\lambda$ . Observa-se que  $\lambda = 0,001$  produziu acurácia média de 99,63% e  $\lambda = 0,01$  atingiu o pico de 99,65%, sendo este o valor selecionado como ótimo. À medida que  $\lambda$  cresce, a acurácia decresce, chegando a 96,25% em  $\lambda = 1$ , o que indica que as matrizes de covariância individuais de cada classe carregam informação discriminativa relevante, e que suavizá-las excessivamente em direção à covariância comum pode degradar o desempenho do classificador.




Fig. 5. Acurácia média do classificador de Friedman por  $\lambda$ .

4) *Validação por Monte Carlo ( $R=500$ ):* A Tabela III consolida os resultados das 500 rodadas de Monte Carlo para todos os classificadores implementados. O histograma da Figura 6 complementa essa análise, exibindo a distribuição das acurácias obtidas em cada rodada.

TABLE III  
RESULTADOS DE ACURÁCIA - MONTE CARLO ( $R=500$ )

| Modelo                                      | Média  | Desv.-Pad. | Maior  | Menor  |
|---------------------------------------------|--------|------------|--------|--------|
| <b>MQO Tradicional</b>                      | 0,7239 | 0,0066     | 0,741  | 0,7033 |
| <b>Gaussian o (QDA)</b>                     | 0,967  | 0,0017     | 0,9717 | 0,9614 |
| <b>Gaussian o (Cov. treino)</b>             | 0,9627 | 0,0018     | 0,9673 | 0,9572 |
| <b>Gaussian o (Cov. Agr.)</b>               | 0,9485 | 0,0027     | 0,9556 | 0,9397 |
| <b>Naive Bayes</b>                          | 0,9656 | 0,0017     | 0,9704 | 0,9598 |
| <b>Friedman (<math>\lambda=0,01</math>)</b> | 0,9965 | 0,0005     | 0,9982 | 0,9950 |

O classificador de Friedman com  $\lambda = 0,01$  obteve o melhor desempenho entre todos os modelos, com acurácia média de 99,65% e desvio-padrão de apenas 0,05%, o que representa a distribuição mais concentrada observada no histograma (Figura 6). O MQO confirmou sua limitação para este problema, com acurácia média de 72,39% e distribuição claramente separada dos demais modelos. Os classificadores QDA, LDA, Naive Bayes e Gaussiano com Covariância Agregada agruparam-se na faixa de 94,85% a 96,70%, com desvios-padrão entre 0,0017 e 0,0027, demonstrando boa estabilidade estatística.




Fig. 6. Distribuição das acurácias - Simulação de Monte Carlo ( $R=500$ ).

#### IV. CONCLUSÕES

Na tarefa de regressão, os resultados mostraram que o modelo de média da variável dependente é completamente inadequado como preditor, com  $R^2$  médio negativo ao longo das 500 rodadas. O MQO tradicional demonstrou boa capacidade de ajuste, com  $R^2$  médio de 0,93, capturando de forma satisfatória a tendência linear dominante na faixa de operação do aerogerador. Os modelos de Tikhonov com diferentes valores

de  $\lambda$  produziram resultados praticamente idênticos ao MQO, o que é esperado em cenários de baixa dimensionalidade e sem sobreajuste. Conclui-se que, para este conjunto de dados, a regularização não traz benefício mensurável, mas tampouco prejudica o desempenho, confirmando a robustez do método.

Na tarefa de classificação, os resultados evidenciaram que a natureza não-linear da separação entre as cinco expressões faciais favorece os modelos com fronteiras de decisão quadráticas. O classificador de Friedman com  $\lambda = 0,01$  — valor selecionado por validação cruzada *k-fold* — atingiu acurácia média de 99,65% nas simulações de Monte Carlo, com desvio-padrão mínimo de 0,05%, consolidando-se como o modelo mais preciso e estável do experimento. O desempenho muito inferior do MQO (72,39%) reforça a inadequação de modelos lineares para problemas com fronteiras de decisão complexas. Os classificadores gaussianos intermediários (QDA, LDA, Naive Bayes e Covariância Agregada) atingiram a faixa de 94% a 97%, demonstrando que mesmo hipóteses simplificadoras sobre a estrutura de covariância são suficientes para obter resultados competitivos neste conjunto de dados.